

§ 2.3 最小方差无偏估计与充分统计量

一、最小方差无偏估计

对于一个无偏估计, 方差越小越有效, 方差最小者最有效. 我们有下列定义:

定义1 设 $\hat{\theta}$ 是 θ 的一个无偏估计量, 若对于 θ 的任一方差存在的无偏估计量 $\tilde{\theta}$, 都有

$$D(\hat{\theta}) \leq D(\tilde{\theta}).$$

则称 $\hat{\theta}$ 是 θ 的**最小方差无偏估计(量)**, 缩写为**MVUE**.

最小方差无偏估计存在的情况并不多, 关于**MVUE**有如下一个判断准则.

定理2.3.1 设 $X = (X_1, X_2, \dots, X_n)$ 是来自某总体的一个样本, $\hat{\theta} = \hat{\theta}(X)$ 是 θ 的一个无偏估计, $D(\hat{\theta}) < \infty$. 如果对任意一个满足 $E(L(X)) = 0$ 的 $L(X)$, 都有

$$\text{Cov}_{\theta}(\hat{\theta}, L) = 0, \text{ (或者 } E(\hat{\theta}L) = 0 \text{)}$$

则 $\hat{\theta}$ 是 θ 的**最小方差无偏估计** (即MVUE).

证明 $\hat{\theta}_1(X)$ 是 θ 的任一无偏估计, 记

$$L(X) = \hat{\theta}_1(X) - \hat{\theta}(X),$$

则 $L(X)$ 的数学期望为0, 由于

$$\begin{aligned} D[\hat{\theta}_1(X)] &= D[\hat{\theta}(X) + L(X)] \\ &= D[\hat{\theta}(X)] + D[L(X)] + 2\text{Cov}(\hat{\theta}, L) \geq D[\hat{\theta}(X)]. \end{aligned}$$

故 $\hat{\theta}$ 是 θ 的MVUE。

推论 参数 θ 的最小方差无偏估计如果存在, 那么它是唯一的(在概率1的意义下).

例1 设 $X = (X_1, X_2, \dots, X_n)$ 是来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 已知 \bar{X} 和 S^2 分别是 μ 和 σ^2 的无偏估计, 证明 \bar{X} 和 S^2 分别是 μ 和 σ^2 的MVUE.

证明 设 $L(X)$ 满足 $EL(X) = \mathbf{0}$, 则有

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx = 0 \quad (1)$$

上式关于 μ 求导, 并利用 (1) 整理得

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} L \cdot \left(\sum_{i=1}^n x_i\right) \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx = 0 \quad (2)$$

故有 $E\left\{\left(\sum_{i=1}^n X_i\right) \cdot L(X)\right\} = \mathbf{0}$.

因而 $E\{\bar{X} \cdot L(X)\} = \mathbf{0}$, \bar{X} 是 μ 的MVUE.

(2) 式关于 μ 求导, 并利用(1), (2)得

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \left(\sum_{i=1}^n x_i \right)^2 \cdot L \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0 \quad (3)$$

(1) 式左边关于 σ^2 求导, 得

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \sum_{i=1}^n (x_i - \mu)^2 \cdot L \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0 \quad (4)$$

利用 $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n\bar{x}^2 + 2n\mu\bar{x} - n\mu^2$ 得

$$\frac{1}{(\sqrt{2\pi}\sigma)^n} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} \sum_{i=1}^n (x_i - \bar{x})^2 \cdot L \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0 \quad (5)$$

故有 $E \{ S^2 \cdot L(X) \} = 0$

所以 S^2 是参数 σ^2 的MVUE.

为了寻找最小方差无偏估计，引进充分统计量和完备统计量的概念。充分统计量是数理统计学的重要概念之一，因为它完整的简缩了样本提供的全部信息。

二、充分统计量和完备统计量

1 充分统计量

1922年英国统计学家Fisher提出了描述总体信息是否被完全提炼的概念——充分统计量。

样本 (X_1, \dots, X_n) 有一个分布 $F(x_1, \dots, x_n; \theta)$ ，这个分布包含了样本中一切有关 θ 的信息，这是我们

一切统计推断的基础.

粗略的说, 一个统计量是充分的, 如果有关估计参数的所有信息都集中在它的值中. 更确切地, 当给定统计量 $T(X_1, X_2, \dots, X_n)$ 的值, 即 $T = t$, 样本 (X_1, X_2, \dots, X_n) 的条件分布 $F(x_1, x_2, \dots, x_n; \theta | t)$ 与 θ 无关. 则称 T 是充分统计量.

定义2 设 X_1, X_2, \dots, X_n 是来自总体 X 具有分布函数 $F(x, \theta)$ 的一个样本, $T = T(X_1, X_2, \dots, X_n)$ 为一个(一维或多维)统计量, 当给定 $T = t$ 时, 若样本 $(X_1, X_2, \dots, X_n)^T$ 的条件分布与参数 θ 无关, 则称 T 为 θ 的充分统计量.

充分统计量 T 中包含了关于 θ 的全部信息, 如果知道了 T 的观察值以后, 样本的条件分布与 θ 无关, 因此要做关于 θ 的统计推断, 只需用统计量 T 就足够了.

例1 设总体 X 服从两点分布 $B(1, p)$, 即

$$P\{X = x\} = p^x (1-p)^{1-x}, x = 1, 0,$$

$(X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本. 试证

(1) \bar{X} 是参数 p 的充分统计量.

(2) $S = X_1 + X_2 (n > 2)$ 不是参数 p 的充分统计量.

证 利用定义证明 \bar{X} 是充分统计量

$$\begin{aligned} & P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n \mid \bar{X} = k/n\} \\ &= \frac{P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n, \bar{X} = k/n\}}{P\{\bar{X} = k/n\}} \\ &= \frac{P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n, n\bar{X} = k\}}{P\{n\bar{X} = k\}} \\ &= \frac{P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n, \sum X_i = k\}}{P\{\sum X_i = k\}} \\ &= \frac{P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\}}{P\{\sum X_i = k\}}. \end{aligned}$$

$$\begin{aligned}
&= \frac{P\{X_1 = x_1\}P\{X_2 = x_2\} \cdots P\{X_n = x_n\}}{P\{\sum X_i = k\}} \\
&= \begin{cases} \frac{p^{\sum x_i} (1-p)^{n-\sum x_i}}{C_n^k p^k (1-p)^{n-k}}, & \sum x_i = k, \\ 0, & \text{其他.} \end{cases} = \begin{cases} \frac{1}{C_n^k}, & \sum x_i = k, \\ 0, & \text{其他.} \end{cases}
\end{aligned}$$

显然该条件分布与 p 无关，因而 \bar{X} 是 p 的充分统计量。

对 $S = X_1 + X_2 (n > 2)$. 由于它只用了前面两个样本观测值，显然没有包含样本中所有关于 p 的信息，在给定 S 的取值 s 后，对任意的一组 $x_1, \cdots, x_n (x_1 + x_2 = s)$. 有

$$\begin{aligned}
& P(X_1 = x_1, \cdots, X_n = x_n \mid S = s) \\
&= \frac{P(X_1 = x_1, X_2 = s - x_1, X_3 = x_3, \cdots, X_n = x_n)}{P(x_1 + x_2 = s)} \\
&= \frac{1}{C_2^s p^s (1-p)^{2-s}} p^{s + \sum_{i=3}^n x_i} (1-p)^{n-s - \sum_{i=3}^n x_i} \\
&= \frac{1}{C_2^s} p^{\sum_{i=3}^n x_i} (1-p)^{n-2 - \sum_{i=3}^n x_i}
\end{aligned}$$

这个分布依赖于未知参数 p ，这说明样本中关于 p 的信息没有完全包含在统计量 S 中。因而 $S = X_1 + X_2 (n > 2)$ 不是参数 p 的充分统计量。

注：对例1而言

$$T_1 = (X_1, X_2, X_3, \dots, X_n), \quad T_2 = (X_1 + X_2, X_3, \dots, X_n)$$

.....

$$T_{n-1} = \left(\sum_{i=1}^{n-1} X_i, X_n \right), \quad T_n = \sum_{i=1}^n X_i.$$

都是参数 p 的充分统计量. 显然 T_n 最好(维数最低).

利用定义判别充分统计量比较麻烦，因而需要需求更好的判别准则.

2. 充分统计量的判别准则

定理2.3.2 （因子分解定理）(Fisher-Neyman准则)

设总体概率函数为 $f(x; \theta)$, X_1, \dots, X_n 为样本, 则 $T = T(X_1, \dots, X_n)$ 为充分统计量的充分必要条件是: 存在两个函数 $g(t, \theta)$ 和 $h(x_1, \dots, x_n)$, 使得对任意的 θ 和任意一组观测值 x_1, \dots, x_n , 有

$$f(x_1, \dots, x_n; \theta) = g[T(x_1, \dots, x_n), \theta] h(x_1, \dots, x_n)$$

其中 $g(T, \theta)$ 是通过统计量 T 的取值而依赖于样本 x_1, x_2, \dots, x_n .

证明：给出离散型随机变量下的证明。此时

$$f(x_1, \cdots, x_n; \theta) = P(X_1 = x_1, \cdots, X_n = x_n; \theta)$$

必要性 设 T 是充分统计量，则

$$P(X_1 = x_1, \cdots, X_n = x_n | T = t)$$

与 θ 无关，记为 $h(x_1, \cdots, x_n)$ ，则在 $T = t$ 下，令

$$A(t) = \{(x_1, \cdots, x_n) : T(x_1, \cdots, x_n) = t\},$$

当 $(x_1, \cdots, x_n) \in A(t)$ 时，有

$$\{X_1 = x_1, \cdots, X_n = x_n\} \subset \{T = t\}$$

$$P(X_1 = x_1, \cdots, X_n = x_n; \theta)$$

$$= P(X_1 = x_1, \cdots, X_n = x_n, T = t; \theta)$$

$$\begin{aligned}
&= P(X_1 = x_1, \cdots, X_n = x_n \mid T = t)P(T = t; \theta) \\
&= h(x_1, \cdots, x_n)g(t, \theta)
\end{aligned}$$

其中 $g(t, \theta) = P(T = t; \theta)$, 而

$$h(x_1, \cdots, x_n) = P(X_1 = x_1, \cdots, X_n = x_n \mid T = t)$$

与 θ 无关. 必要性得证.

充分性, 由于

$$\begin{aligned}
P(T = t; \theta) &= \sum_{\{(x_1, \cdots, x_n): T=t\}} P(X_1 = x_1, \cdots, X_n = x_n; \theta) \\
&= \sum_{\{(x_1, \cdots, x_n): T=t\}} g(t, \theta) h(x_1, \cdots, x_n)
\end{aligned}$$

对任给 (x_1, \cdots, x_n) 和 t 满足 $(x_1, \cdots, x_n) \in A(t)$, 有

$$\begin{aligned}
& P(X_1 = x_1, \dots, X_n = x_n \mid T = t) \\
&= \frac{P(X_1 = x_1, \dots, X_n = x_n, T = t; \theta)}{P(T = t; \theta)} \\
&= \frac{P(X_1 = x_1, \dots, X_n = x_n, T = t; \theta)}{P(T = t; \theta)} \\
&= \frac{g(t, \theta) h(x_1, \dots, x_n)}{g(t, \theta) \sum_{\{(y_1, \dots, y_n): T(y_1, \dots, y_n) = t\}} h(y_1, \dots, y_n)} \\
&= \frac{h(x_1, \dots, x_n)}{\sum_{\{(y_1, \dots, y_n): T(y_1, \dots, y_n) = t\}} h(y_1, \dots, y_n)}
\end{aligned}$$

该分布与 θ 无关，充分性得证。

说明：如果参数 θ 为向量时，统计量 T 也是随机向量. 例如， $\theta = (\mu, \sigma^2)$ ，则相应的统计量可以为 $T = (\bar{X}, S_n^2)$.

在统计学中有一个基本原则：在充分统计量存在场合，**任何统计推断都可以基于充分统计量进行**，这可以简化统计推断的程序，通常将该原则称为**充分性原则**.

以下将通过几个例子来说明判别法则的应用.

例2 根据因子分解定理证明例1.

证明:
$$P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\}$$
$$= p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} = (1-p)^n \left[p(1-p)^{-1} \right]^{\sum_{i=1}^n x_i}$$
$$= (1-p)^n \left[p(1-p)^{-1} \right]^{n\bar{X}} = g(T; p)h(x_1, x_2, \cdots, x_n).$$

其中 $T = \bar{X}$, $g(T, p) = (1-p)^n \left[p(1-p)^{-1} \right]^{nT}$,

$$h(x_1, x_2, \cdots, x_n) = 1,$$

因而 \bar{X} 是充分统计量.

例3 设 $(X_1, X_2, \cdots, X_n)^T$ 是来自泊松分布 $P(\lambda)$ 的一个样本, 试证 \bar{X} 是参数 λ 的充分统计量.

证明: $P\{X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n\}$

$$= \left(\prod_{i=1}^n x_i!\right)^{-1} \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda} = \left(\prod_{i=1}^n x_i!\right)^{-1} \lambda^{n\bar{X}} e^{-n\lambda}.$$

其中 $T(x_1, x_2, \cdots, x_n) = \bar{X}$, $g(T, \lambda) = \lambda^{nT} e^{-n\lambda}$,

$$h(x_1, x_2, \cdots, x_n) = \left(\prod_{i=1}^n x_i!\right)^{-1},$$

因而 \bar{X} 是充分统计量.

例4 设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, 1)$ 的一个样本, 试证 \bar{X} 是参数 μ 的充分统计量.

证明

$$\begin{aligned} L(\mu) &= \frac{1}{(\sqrt{2\pi})^n} e^{-\{\frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\}} \\ &= \frac{1}{(\sqrt{2\pi})^n} \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu)^2\right\} \\ &= \frac{1}{(\sqrt{2\pi})^n} \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2 - \frac{n}{2} (\bar{x} - \mu)^2\right\} \\ &= \frac{1}{(\sqrt{2\pi})^n} \exp\left\{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2\right\} \exp\left\{-\frac{n}{2} (\bar{x} - \mu)^2\right\} \\ &= h(x_1, x_2, \dots, x_n) g(T, \mu). \end{aligned}$$

其中 $h(x_1, x_2, \dots, x_n) = \exp\{-\frac{1}{2} \sum_{i=1}^n (x_i - \bar{x})^2\}$,

$$T(x_1, x_2, \dots, x_n) = \bar{x},$$

$$g(T, \mu) = \frac{1}{(\sqrt{2\pi})^n} \exp\{-\frac{n}{2}(T - \mu)^2\},$$

因而, \bar{X} 是充分统计量.

练习题

设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 试证 $T(X_1, X_2, \dots, X_n) = (\bar{X}, \sum_{i=1}^n X_i^2)^T$ 是参数 $\theta = (\mu, \sigma^2)^T$ 的(联合)充分统计量.

答案: $L(\theta) = L(\mu, \sigma^2) = \frac{1}{(\sqrt{2\pi}\sigma)^n} e^{-\{\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\}}$

$$= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{n\mu}{\sigma^2} \bar{x} - \frac{n\mu^2}{2\sigma^2}\right\}$$

$$= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{n\mu}{\sigma^2} \bar{x} - \frac{n\mu^2}{2\sigma^2}\right\},$$

其中 $T(x_1, x_2, \dots, x_n) = (\bar{x}, \sum_{i=1}^n x_i^2)^T$, $h(x_1, x_2, \dots, x_n) = 1$,

$$g(T(x_1, x_2, \dots, x_n), \theta)$$

$$= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n x_i^2 + \frac{n\mu}{\sigma^2} \bar{x} - \frac{n\mu^2}{2\sigma^2}\right\},$$

因而, $T(X_1, X_2, \dots, X_n) = (\bar{X}, \sum_{i=1}^n X_i^2)^T$ 是充分统计量.

为了从充分统计量出发，去寻找最小方差无偏估计，我们先给出几个定理.

定理2.3.3 (Rao – Blackwell定理)

设 X 和 Y 是两个随机变量, $EX = \mu$, $D(X) > 0$. 定义

$$\varphi(y) = E(X | Y = y),$$

则有

$$E[\varphi(Y)] = \mu, \quad D[\varphi(Y)] \leq D(X),$$

其中等号成立的充要条件是 X 和 $\varphi(Y)$ 概率 1 相等.

证明：不妨设 X 和 Y 都是连续型随机变量，设 $p(x, y), p_Y(y), h(x | y)$ 分别是 X 和 Y 的联合密度函数 Y 的边际密度函数和给定 $Y = y$ 下 X 的条件密度函数.

于是条件期望

$$\varphi(y) = E(X | Y = y) = \int_{-\infty}^{+\infty} xh(x | y)dx = \frac{\int_{-\infty}^{+\infty} xp(x, y)dx}{p_Y(y)},$$

$$E[\varphi(Y)] = \int_{-\infty}^{+\infty} \varphi(y)p_Y(y)dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xp(x, y)dxdy = EX = \mu,$$

这证明了第一个结论,下证第二个结论:

$$\begin{aligned} D(X) &= E(X - \mu)^2 \\ &= E\left[(\varphi(Y) - \mu) + (X - \varphi(Y))\right]^2 \\ &= D[\varphi(Y)] + E(X - \varphi(Y))^2 \\ &\quad + 2E\left[(\varphi(Y) - \mu) \cdot (X - \varphi(Y))\right] \end{aligned}$$

由于

$$\int_{-\infty}^{+\infty} [x - \varphi(y)] h(x | y) dx = E(X | Y = y) - \varphi(y) = 0,$$

故上式右端第三项为

$$\begin{aligned} & E[(\varphi(Y) - \mu)(X - \varphi(Y))] \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [\varphi(y) - \mu][x - \varphi(y)] p(x, y) dx dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [\varphi(y) - \mu][x - \varphi(y)] p_Y(y) h(x | y) dx dy \\ &= \int_{-\infty}^{+\infty} [\varphi(y) - \mu] dx \left\{ \int_{-\infty}^{+\infty} [x - \varphi(y)] h(x | y) dx \right\} p_Y(y) dy = 0, \end{aligned}$$

因而 $D(X) = D(\varphi(Y)) + E(X - \varphi(Y))^2 \geq D(\varphi(Y))$

且等号成立的充要条件是 $P(X - \varphi(Y) = 0) = 1$

即 X 与 $\varphi(Y)$ 概率1相等.

将定理2.3.3应用在参数估计中可得：

定理2.3.4 设总体的概率函数为 $p(x; \theta)$, 设 X_1, \dots, X_n 是样本, $T = T(X_1, \dots, X_n)$ 是 θ 的充分统计量, 对 θ 的任一无偏估计 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. 令 $\tilde{\theta} = E(\hat{\theta} | T)$, 则 $\tilde{\theta}$ 也是 θ 的无偏估计, 且

$$D(\tilde{\theta}) \leq D(\hat{\theta}).$$

证明： 由于 $T = T(x_1, \dots, x_n)$ 是充分统计量, 故 $\tilde{\theta} = E(\hat{\theta} | T)$ 与 θ 无关, 因此它也是一个估计(统计量), 只要在定理2中取 $X = \hat{\theta}, Y = T$ 即可.

定理4说明：如果无偏估计不是充分统计量的函数，则求其对充分统计量的条件期望，可以得到一个新的无偏估计，该新无偏估计的方差比原估计的方差要小，从而降低了无偏估计的方差。

只要最小方差无偏估计存在.它一定是充分统计量的函数.一般地,若依赖于充分统计量的无偏估计只有一个,它一定是MVUE.(见完备统计量)

考虑 θ 的估计问题只需要在基于充分统计量的函数中进行即可，该说法对所有的统计推断问题都是正确的，这便是所谓的充分性原则。

例6 设 X_1, X_2, \dots, X_n 是来自 $B(1, p)$ 的样本, 则

$T = \sum_{i=1}^n X_i$ 是 p 的充分统计量. 为估计 $\theta = p^2$, 可令

$$\hat{\theta}_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1 \\ 0, & \text{其它} \end{cases}$$

由于 $E(\hat{\theta}_1) = P(x_1 = 1, x_2 = 1) = p^2 = \theta$. 所以 $\hat{\theta}_1$ 是 θ 的无偏估计.

$$D(\hat{\theta}_1) = p^2(1 - p^2)$$

这个只使用了两个观测值的估计并不好, 下面我们
我们用**Rao – Blackwell**定理对之加以改进:

求 $\hat{\theta}_1$ 关于充分统计量 $T = \sum_{i=1}^n X_i$ 的条件期望，得

$$\hat{\theta} = E(\hat{\theta}_1 | T = t)$$

$$= 1 \times P(\hat{\theta}_1 = 1 | T = t) + 0 \times P(\hat{\theta}_1 = 0 | T = t)$$

$$= P(\hat{\theta}_1 = 1 | T = t) = C_{n-2}^{t-2} / C_n^t = \frac{t(t-1)}{n(n-1)},$$

$$\hat{\theta} = \frac{T(T-1)}{n(n-1)}.$$

T 的函数

$$E(\hat{\theta}) = E\left(\frac{T(T-1)}{n(n-1)}\right) = \frac{E(T^2) - E(T)}{n(n-1)}$$

$$= \frac{(np)^2 + np(1-p) - np}{n(n-1)} = p^2$$

无偏估计

$T \sim B(n, p)$, 根据二项分布的特征函数

$$f(t) = (pe^{it} + q)^n$$

可求得

$$f'(t) = i \cdot npe^{it} (pe^{it} + q)^{n-1}$$

$$f''(t) = if'(t) + i^2 n(n-1)p^2 e^{2it} (pe^{it} + q)^{n-2}$$

$$f'''(t) = 3if''(t) + 2f'(t) +$$

$$i^3 n(n-1)(n-2)p^3 e^{3it} (pe^{it} + q)^{n-3}$$

$$f^{(4)}(t) = 3if'''(t) + 2f''(t) + i^3 n(n-1)(n-2)p^3$$

$$\left[3ie^{3it} (pe^{it} + q)^{n-3} + i(n-3)pe^{4it} (pe^{it} + q)^{n-4} \right]$$

再由 $f^{(k)}(0) = i^k ET^k$ 得

$$E(T^2) = np + n(n-1)p^2$$

$$E(T^3) = np + 3n(n-1)p^2 + n(n-1)(n-2)p^3$$

$$E(T^4) = np + 7n(n-1)p^2 + 6n(n-1)(n-2)p^3 \\ + n(n-1)(n-2)(n-3)p^4$$

$$E(T^2 - T)^2 = E(T^4 - 2T^3 + T^2) \\ = 2n(n-1)p^2 + 4n(n-1)(n-2)p^3 \\ + n(n-1)(n-2)(n-3)p^4$$

$$D(\hat{\theta}) = D\left(\frac{T(T-1)}{n(n-1)}\right) = E\left(\frac{T(T-1)}{n(n-1)}\right)^2 - p^4$$

$$= p^2 \times \left(\frac{2 + 4(n-2)p + (n-2)(n-3)p^2}{n(n-1)} - p^2 \right) \quad \boxed{\text{方差变小}}$$

$$< p^2 \times \left(\frac{2 + 4(n-2) + (n-2)(n-3)}{n(n-1)} - p^2 \right) = p^2(1 - p^2)$$

3 完备统计量

由上面可知:只要最小方差无偏估计存在,它一定是充分统计量的函数. 如果依赖于充分统计量的无偏估计只有一个,它一定是最小方差无偏估计. 那么何时它是唯一的? 为此引入完备性的概念.

定义3 设总体的分布函数为 $F(x, \theta) (\theta \in \Theta)$, 若对于任意一个满足

$$E_{\theta}[g(X)] = 0, \text{ 对一切 } \theta \in \Theta,$$

的随机变量 $g(X)$, 总有

$$P_{\theta}\{g(X) = 0\} = 1, \text{ 对一切 } \theta \in \Theta,$$

则称 $\{F(x, \theta), \theta \in \Theta\}$ 是完备的分布函数族.

设 X_1, X_2, \dots, X_n 是来自总体 X 具有分布函数 $F(x, \theta)$ 的一个样本, $T = T(X_1, X_2, \dots, X_n)$ 的分布函数是完备的, 则称 $T = T(X_1, X_2, \dots, X_n)$ 为**完备统计量**.

完备统计量: 若 T 的实值函数 $g(T)$ 满足:

$$E(g(T)) = 0,$$

对一切 $\theta \in \Theta$ 成立时, 总有

$$P\{g(T) = 0\} = 1.$$

则称 T 是完备统计量.

即: 如果 $g(T)$ 数学期望为0, 则它必概率1取值为0.

例7 设总体 X 服从两点分布 $B(1, p)$, 即

$$P\{X = x\} = p^x (1-p)^{1-x}, x = 1, 0.$$

X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 试证 \bar{X} 是参数 p 的完备统计量.

证明: 由于 $P\{\bar{X} = \frac{k}{n}\} = P\{n\bar{X} = k\} = C_n^k p^k (1-p)^{n-k}$,

如果 $E_p(g(\bar{X})) = \sum_{k=0}^n g(\frac{k}{n}) C_n^k p^k (1-p)^{n-k} = 0$, 则

$$(1-p)^n \sum_{k=0}^n g(\frac{k}{n}) C_n^k (\frac{p}{1-p})^k = 0,$$

得 $g(\frac{k}{n}) = 0$, $g(\bar{X}) = 0$.

充分完备统计量

如果一个统计量既是充分的，又是完备的，则称为充分完备统计量.

定理2.3.5: 设总体 X 的分布函数为 $F(x, \theta), \theta \in \Theta$. X_1, X_2, \dots, X_n 是总体样本, $T = T(X_1, X_2, \dots, X_n)$ 是充分完备统计量. 如果 θ 的无偏估计存在, 记为 $\hat{\theta}$. 则 $\tilde{\theta} = E(\hat{\theta} | T)$ 是唯一的最小方差无偏估计.

证明: 练习题.

判断一个统计量 $T(X_1, X_2, \dots, X_n)$ 是否为充分完备统计量比较复杂, 为此介绍一类分布族, 其参数的充分完备统计量容易寻找.

4、指数型分布族的概念

定义1.7 设总体 X 的概率函数为 $f(x, \theta)$, 其中 θ 未知且 $\theta \in \Theta$, 如果存在定义在参数空间上的实值函数 $c(\theta)$, $d(\theta)$ 和实值函数 $T(x)$, $S(x)$, 使得

$$f(x, \theta) = \exp\{C(\theta)T(x) + d(\theta) + h(x)\}$$

则称 $\{f(x, \theta) \mid \theta \in \Theta\}$ 为单参数指数分布族.

例如: (1) 正态分布 $N(\mu_0, \sigma^2)$, 已知 μ_0 , 关于参数 σ ;

(2) 正态分布 $N(\mu, \sigma_0^2)$, 已知 σ_0 , 关于参数 μ ;

(3) 泊松分布 $P(\lambda)$ 关于参数 λ .

但是 $[0, \theta]$ 上的均匀分布不是参数 θ 的单参数分布族.

一般地, 泊松分布族, 二项分布族, 正态分布族, 伽玛分布族等, 其中只要有一个参数是已知常数, 则都属于单参数指数分布族.

注: 定义中的函数 c, d, h 和 T 不唯一. 类似的有多参数的指数分布族的概念.

设 X_1, X_2, \dots, X_n 是来自单参数指数分布族 X 的样本, 则样本的联合概率函数为

$$\prod_{i=1}^n f(x_i, \theta) = \exp\{C(\theta) \sum_{i=1}^n T(x_i) + nd(\theta) + \sum_{i=1}^n h(x_i)\}$$

根据因子分解定理, $\sum_{i=1}^n T(x_i)$ 是 θ 的充分统计量.

可以证明它也是完备统计量.

例8 设 $(X_1, X_2, \dots, X_n)^T$ 是来自泊松分布 $P(\lambda)$ 的一个样本, 试证 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是参数 λ 的充分完备统计量.

证明:

$$\begin{aligned} P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} &= \lambda^{\sum_{i=1}^n x_i} e^{-n\lambda} \left(\prod_{i=1}^n x_i! \right)^{-1} \\ &= \lambda^{n\bar{x}} e^{-n\lambda} \left(\prod_{i=1}^n x_i! \right)^{-1} = \exp\{ \bar{X} \times n \ln \lambda - n\lambda - \ln(\prod_{i=1}^n x_i!) \} \end{aligned}$$

其中 $T = \bar{X}$, $C(\lambda) = n \ln \lambda$,

$$nd(\lambda) = -n\lambda, \quad \sum_{i=1}^n h(x_i) = \left(\prod_{i=1}^n x_i! \right)^{-1}.$$

因而 \bar{X} 是充分完备统计量

练习题 设 $(X_1, X_2, \dots, X_n)^T$ 是来自均匀分布 $U(0, \theta)$ 的一个样本, $\theta > 0$ 。试求参数 θ 的最小方差无偏估计。
(提示: 从参数的极大似然估计出发去求解)

关于多维参数的情况有下列定理：

定理2.3.6： 设总体 X 的分布密度为 $f(x, \theta)$ 为指数型分布族，即样本的联合分布密度具有形式

$$\prod_{i=1}^n f(x_i, \theta) = \exp\left\{\sum_{j=1}^m b_j(\theta) T_j(x_1, x_2, \dots, x_n) + d(\theta) + h(x_1, x_2, \dots, x_n)\right\}$$

其中 $\theta = (\theta_1, \dots, \theta_m)^T, \theta \in \Theta$. 如果 Θ 包含一个 m 维矩形，且 $B = (b_1(\theta), \dots, b_m(\theta))^T$ 的值域包含一个 m 维开集，则 $T = (T_1(X_1, \dots, X_n), T_2(X_1, \dots, X_n), \dots, T_m(X_1, \dots, X_n))^T$ 是参数 $\theta = (\theta_1, \theta_2, \dots, \theta_m)^T$ 的充分完备统计量.

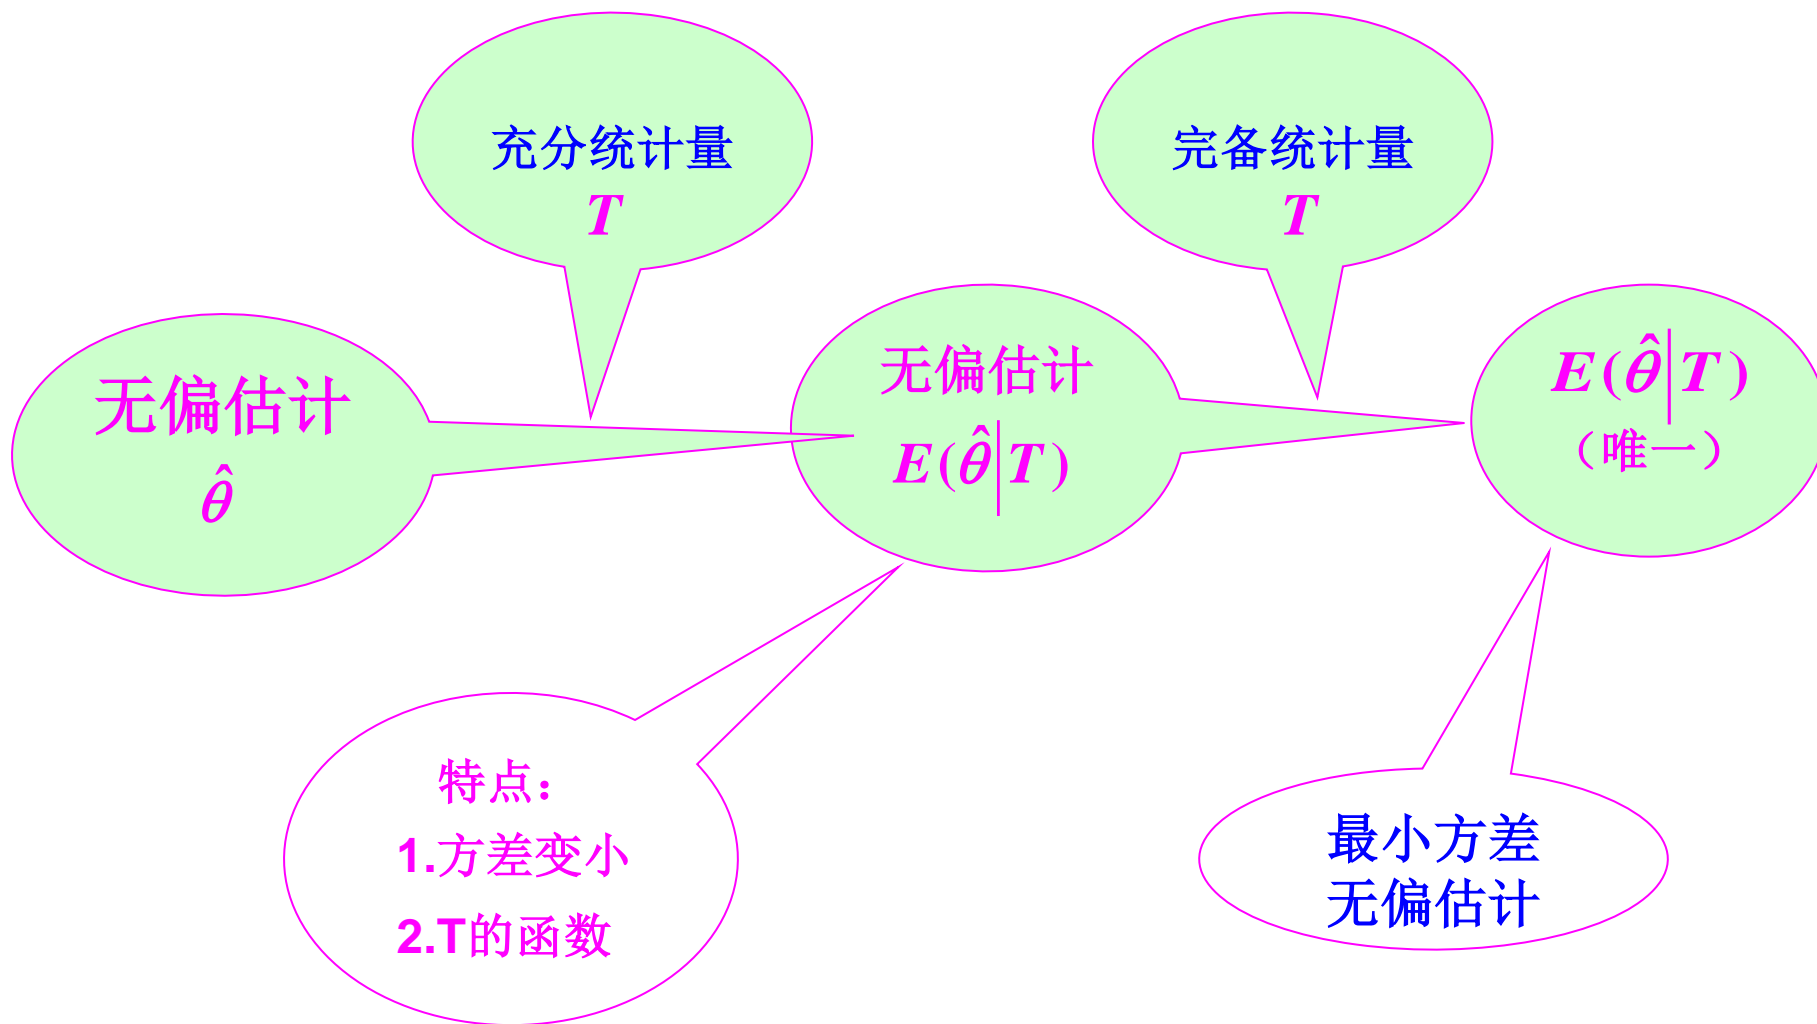
例9 设 $(X_1, X_2, \dots, X_n)^T$ 是来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 试证 $T(X_1, X_2, \dots, X_n) = (\bar{X}, \frac{1}{n} \sum_{i=1}^n X_i^2)^T$ 是参数 $\theta = (\mu, \sigma^2)^T$ 的联合充分完备统计量.

(\bar{X}, S^2) 也是 $(\mu, \sigma^2)^T$ 的充分完备统计向量. 又 \bar{X}, S^2 分别为 μ 和 σ^2 的无偏估计, 且

$$\hat{\mu} = E(\bar{X} | T) = \bar{X}, \quad \hat{\sigma}^2 = E(S^2 | T) = S^2.$$

由定理知: \bar{X}, S^2 分别为 μ 和 σ^2 的惟一的最小方差无偏估计.

单指数分布族具有充分完备统计量



练习题 设 $(X_1, X_2, \dots, X_n)^T$ 是来自均匀分布 $U(0, \theta)$ 的一个样本, $\theta > 0$ 。试求参数 θ 的最小方差无偏估计。
(提示: 从参数的极大似然估计出发去求解)

证明: $T = X_{(n)}$ 是充分统计量, 也是完备统计量, 因为其密度函数为

$$f_T(t) = n[F(t)]^{n-1} f(t) = \frac{n}{\theta^n} t^{n-1}, \quad 0 < t < \theta, \theta > 0.$$

如果对任一可测函数 $g(t)$, 有

$$E(g(T)) = 0,$$

即
$$\int_0^\theta g(t) \frac{n}{\theta^n} t^{n-1} dt = 0, \quad \theta > 0.$$

所以
$$\int_0^\theta g(t) t^{n-1} dt = 0, \quad \theta > 0.$$

等式两边对 θ 求导数得

$$g(\theta) \theta^{n-1} = 0, \quad \theta > 0.$$

所以 $\theta > 0$ 时, $g(\theta) = 0$, 也就是

$$g(t) = 0, \quad \theta > 0.$$

所以 $T = X_{(n)}$ 完备统计量.

由于 $\frac{n+1}{n} X_{(n)}$ 是 θ 的无偏估计, 且是 $X_{(n)}$ 的函数。

因此是 θ 的最小方差无偏估计.